

Sport Summarizer

Sumarização Extrativa de Laudos Esportivos
baseada em Grafos e PageRank

ESTRUTURAS DE DADOS 2 | UNB FGA

GRUPO 5

Bruno de Oliveira

Eduardo Ribeiro Gomes da Silva

João Pedro de Sousa Silva

Lara Giuliana Lima dos Santos

Pedro Vieira Antunes

DESCRIÇÃO DO PROBLEMA

ITEM 1

O Cenário Crítico

Imagine uma final de campeonato ou o último dia da janela de transferências. Treinadores e diretores possuem minutos (ou segundos) para tomar decisões de alto impacto financeiro e tático baseadas na condição de um atleta.

A Avalanche de Dados

O departamento de Scout e Médico entrega um relatório denso de 4 páginas. O excesso de dados não estruturados (jargões táticos e médicos) gera fadiga cognitiva, escondendo informações cruciais sobre lesões ou deficiências.

Nosso objetivo: Utilizar teoria dos grafos para filtrar o ruído e extrair a essência vital do texto instantaneamente.

MODELAGEM DO GRAFO

ITEM 2

1. Os Vértices (Nós)

Cada frase isolada do laudo (após tratamento NLP) é transformada em um nó do nosso grafo.

2. As Arestas e Pesos

Arestas não-direcionadas conectam as frases. O peso da aresta é calculado pelo Índice de Similaridade de Jaccard (interseção de palavras relevantes).

Índice de Jaccard


$$J(A, B) = \frac{A \cap B}{A \cup B}$$

* Arestas só são criadas se $J > 0.02$ (Limiar de corte).

DESCRIÇÃO DA SOLUÇÃO

ITEM 3

Uma linha de montagem de dados operando em 5 estágios estruturais:



IMPLEMENTAÇÃO E ESTRUTURAS

ITEM 4

🐍 **Linguagem Base:** Python 3

🚫 **Zero Bibliotecas Prontas:** Toda a lógica de grafos foi codificada do zero na classe `GrafoMatriz`. O uso da *NetworkX* foi estritamente evitado conforme as regras.

⚙️ **Segunda Estrutura: Max-Heap.** Uma Árvore Binária de Prioridade foi implementada via array (`heap.py`) com métodos `_subir()` e `_descer()` manuais.

⚡ Por que o Max-Heap?

Após o algoritmo purista do **PageRank** calcular os scores de centralidade (em $O(I * V^2)$), precisávamos extrair as 3 frases mais vitais. O Max-Heap garante que a extração do Top-K ocorra em tempo logarítmico $O(k \log V)$, o que é absurdamente eficiente para o processamento em tempo real exigido no esporte de alto nível.

EXEMPLOS DE ENTRADA E SAÍDA

ITEM 5

JSON Entrada (Texto Bruto)

```
"O atleta apresenta desenvolvimento técnico consistente... Na sessão matinal a equipe técnica destacou melhora na cadência do salto e estabilidade... Historicamente ele teve ajuste difícil... Em partidas chave houve episódios repetidos de transição defensiva lenta, sobretudo contra equipes rápidas... Em um lance o atleta posicionou-se mal no pick and roll e permitiu corte direto à cesta... Precisa evoluir no timing de salto... Avaliação tática final: peça importante para o esquema, porém com pontos críticos em transição defensiva."
```

Saída do Pipeline (Top 3)

1. "Em partidas chave houve episódios repetidos de transição defensiva lenta, sobretudo contra equipes com contra-ataque rápido."
2. "O atleta posicionou-se mal no pick and roll e permitiu um corte direto à cesta, evidenciando necessidade de sincronização."
3. "Avaliação tática final: peça importante para o esquema, porém com pontos críticos em transição defensiva."

ANÁLISE DOS RESULTADOS

ITEM 6

~85%

TAXA MÉDIA DE REDUÇÃO

< 2.5s

PROCESSAMENTO LOTE (50 DOCS)

1.0

SOMA PAGERANK (CHECK)

Impacto Direto

O tempo de leitura de um laudo caiu de quase 3 minutos para menos de 10 segundos. O treinador recebe o diagnóstico cirúrgico do atleta a tempo de intervir na partida.

Coerência Semântica

O PageRank garantiu que frases descritivas perdessem força, enquanto as frases de "diagnóstico e ação" (que possuíam termos centrais do grafo) foram puxadas pelo Max-Heap com perfeição.

Obrigado!